

# Supervised Learning

**“선형 모델에서 Weight & bias”와 “feature 수 변화”를 중심으로**

김 양 곤

## 발표 목차

1. Weight & bias
  1. 선형 모델
  2. 신경망
2. feature 줄이기, 늘리기
  1. Kernelized SVM
  2. 결정 트리, 결정 트리 앙상블

## 책의 목차

1. k-최근접 모델
2. 선형 모델
3. 나이브 베이즈 분류
4. 결정 트리
5. 결정 트리 앙상블
6. 커널 SVM
7. 신경망

## 1. 선형 모델 *for Regression*


$$\hat{y} = w[0] \cdot x[0] + w[1] \cdot x[1] + \cdots + w[p] \cdot x[p] + b$$

**w**와 **b**는 학습 시킬 파라미터

**y**는 예측값

**x[0] ... x[p]**는 한 데이터의 feature 값

ex)



$$y = w \cdot x + b$$

x축 : feature

y축 : target

feature가 한 개 일 때, 직선  
두 개 일 때, 평면

## 1. 선형 모델 *for Regression*

W, b를 어떤 조건으로 학습시킬 것인가?

- *Least Squares* : MSE의 **최솟값**을 찾는 것


$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \longrightarrow \quad \begin{aligned} \frac{\partial MSE}{\partial b} &= \frac{1}{n} \frac{\partial \sum_{i=1}^n (y_i - b - wx_i)^2}{\partial b} = 0 \\ \frac{\partial MSE}{\partial w} &= \frac{1}{n} \frac{\partial \sum_{i=1}^n (y_i - b - w_i x_i)^2}{\partial w} = 0 \end{aligned} \quad \longrightarrow \quad \begin{aligned} b &= \bar{y} - w \cdot \bar{x} \\ w &= \frac{\sum x_i (y_i - \bar{y})}{\sum x_i (x_i - \bar{x})} \end{aligned}$$

- *Ridge*  $MSE + \alpha \sum_{i=1}^n w_i^2$  모든 특성이 출력에 주는 영향을 최소화. train data 성능 감소
- *Lasso*  $MSE + \alpha \sum_{i=1}^n |w_i|$  어떤 특성은 출력에 영향을 아예 못 준다 (특정  $w=0$ )  
**feature selection** : 모델에 가장 중요한 특성만 남긴다.

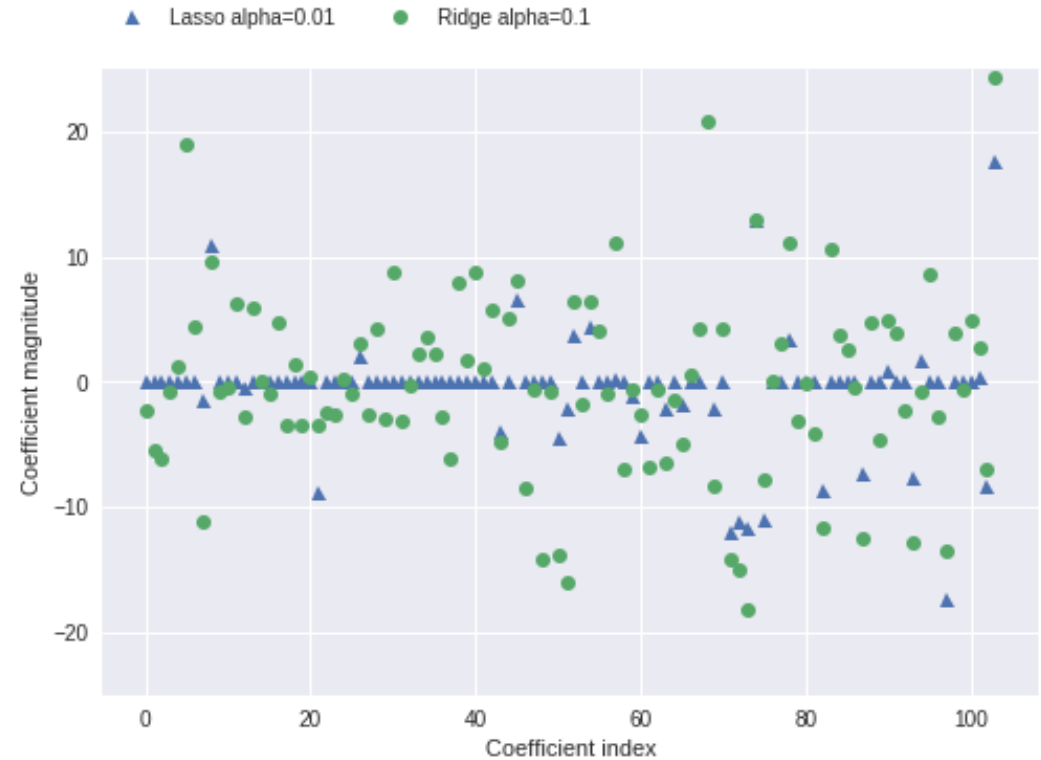
# 1. 선형 모델 *for Regression*

W, b를 어떤 조건으로 학습시킬 것인가?

*Least Squares* VS *Ridge*( $\alpha = 1$ )



*Lasso* ( $\alpha = 0.01$ ) VS *Ridge* ( $\alpha = 0.1$ )




## 1. 선형 모델 *for Classification*

$$\hat{y} = w[0] \cdot x[0] + w[1] \cdot x[1] + \cdots + w[p] \cdot x[p] + b > 0$$

Regression과 달리 Classification에서는  $y$ 가 결정 경계  
Regression과 달리 feature가 두 개 일 때, 직선

## 1. 선형 모델 *for Classification*

ex)



w 배열의 크기 : (3, 2) =>  $(w_{11} \ w_{12}), (w_{21} \ w_{22}), (w_{31} \ w_{32})$

b 배열의 크기 : (3, ) =>  $(b_1), (b_2), (b_3)$



$$w_{11}x + w_{12}y + b_1 = 0$$

$$y = \frac{-(w_{11}x + b_1)}{w_{12}}$$

#세 개의 이진 분류기를 시각화


```
mglearn.discrete_scatter(X[:,0],X[:,1],y)
```

```
line = np.linspace(-15,15)
```


```
for coef, intercept, color in zip(linear_svm.coef_, linear_svm.intercept_,mglearn.cm3.colors):  
    plt.plot(line,-(line*coef[0]+intercept)/coef[1],c=color)
```

## 1. 선형 모델 *for Multilayer Perceptron*

- $\hat{y} = w[0] \cdot x[0] + w[1] \cdot x[1] + w[2] \cdot x[2] + w[3] \cdot x[3]$




- $h = w[0] \cdot x[0] + w[1] \cdot x[1] + w[2] \cdot x[2] + w[3] \cdot x[3]$   
 $\hat{y} = \hat{w}[0] \cdot h[0] + \hat{w}[1] \cdot h[1] + \hat{w}[2] \cdot h[2]$



모델의 예측값이 한번의 weighted sum 연산으로 결정하는 것이 아니라 여러 번에 걸쳐 반복한다.

뇌의 뉴런의 동작 방식을 모방한 것이다.





## 1. Weight & bias

1. 선형 모델
2. 신경망


## 2. feature 줄이기, 늘리기

1. Kernelized SVM
2. 결정 트리, 결정 트리 앙상블

## 2. feature 줄이기, 늘이기

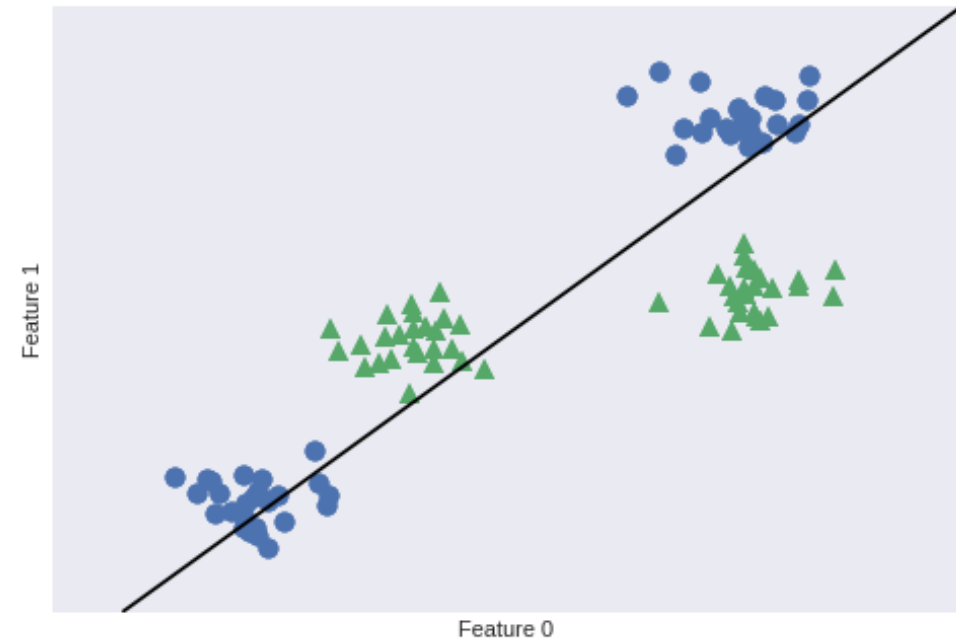
### 선형 Support Vector Machine

Margin을 크게 가지는  $w, b$ 를 찾는다.




출처 : <https://ratsgo.github.io/machine%20learning/2017/05/23/SVM/>

선형 결정 경계를 긋기 힘들다




## 2. feature 줄이기, 늘이기

### Kernelized Support Vector Machine




두번째 feature를 제공하여 추가해주어  
데이터가 마치 세개의 feature를 가진 것 처럼 표현한다

```
← X_new = np.hstack([X, X[:, 1:] ** 2])
```



$ax+by+cz+d=0$  꼴의 선형 결정 경계를 그릴 수 있다

```
← ZZ = (coef[0] * XX + coef[1] * YY + intercept) / -coef[2]
```



임시로 만들어 주었던 세번째 feature를 없애둔다  
(위에서 구한 결정 경계를 xy 평면으로 사영시킨다)

## 2. feature 줄이기, 늘이기

### Kernelized Support Vector Machine

주어진 데이터의 특성을 이용하여 고차원 특성 공간으로 확장  
고차원 특성 공간에서 두 범주를 구분하는 초평면을 찾는 것.

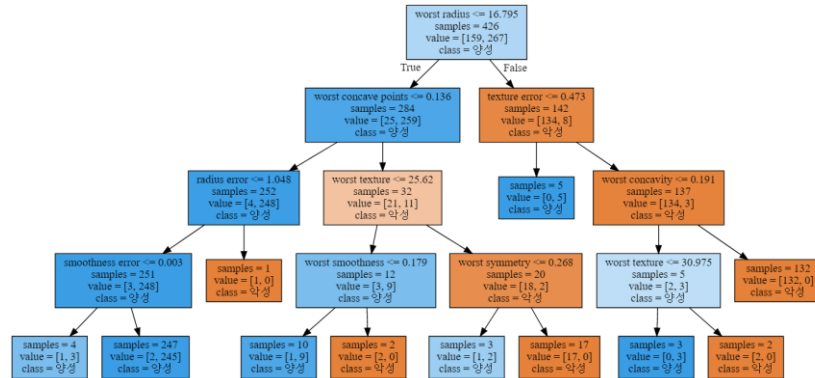
➡ feature을 늘여서 모델의 정확도를 높인다.

반대로, 모델의 정확도를 높이고 보니

데이터의 특성을 명확하게 규정하는 주요 특성만 남아 feature 수가 준 경우도 있다.

## 2. feature 줄이기, 늘이기

### Decision Tree



- breast cancer data : (569, 30)


Tree Classifier의 max depth를 4로 지정

Test set accuracy가 0.951

- 30개의 feature 중 9개 만 사용

“worst radius” feature가 가장 중요한 특성

(특성이 선택 되지 않았다고 해서 유용하지 않다고 단정 지을 수 없음. 다른 특성과 동일한 정보를 지니는데, 단지 선택 받지 못했을 수도 있다)



## 2. feature 줄이기, 늘이기


### Gradient Boosting decision tress

Decision Tree의 단점은 Training Data에 과대 적합 되어 버림.

이 문제를 해결하고자 여러 모델을 연결하여 더 강력한 모델을 만드는 앙상블 기법 사용.

### Gradient Boosting decision tress

이전 트리의 오차를 보완하는 방식으로 강력한 사전 가지 치기(learning\_rate, n\_estimators)



- Test set accuracy가 0.965

30개의 feature 중 18개 만 사용

“worst radius” feature를 비롯한 여러 특성 반영